

Relatório Técnico: Sistema de Visão Computacional para Auditoria de Gôndola (Varejo)

Aluno: Leonardo Ramos Coutinho

Disciplina: Visão Computacional e Reconhecimento de Padrões

Cenário: Varejo, Detecção e Segmentação de Produtos em Prateleiras

Repositório: github.com/lramosc1512/visao-computacional-varejo

Vídeo-pitch: a preencher

1. Problema e Cenário

Auditoria de gôndola é uma tarefa recorrente no varejo: verificar presença, quantidade e organização de produtos expostos nas prateleiras, hoje feita majoritariamente de forma manual. Este projeto constrói um sistema de visão computacional que detecta produtos individuais em fotos de prateleira e segmenta cada instância detectada, permitindo estimar ocupação e apoiar decisões de reposição.

O sistema é dividido em duas granularidades complementares: um detector geral de produtos (classe única), treinado sobre uma base ampla de imagens reais de prateleira; e um modelo de segmentação por categoria, treinado sobre um subconjunto menor e cuidadosamente selecionado, capaz de distinguir grandes grupos de produtos além de apenas localizá-los.

Essa divisão foi uma escolha deliberada de escopo, dado que o projeto foi desenvolvido por uma única pessoa: anotar segmentação e categoria em todas as instâncias de uma base densamente povoada não é viável no prazo do curso. A estratégia concentra o esforço manual de anotação apenas onde ele é indispensável, e aproveita anotações já existentes para a detecção.

2. Dataset e Análise Exploratória

2.1 Fonte dos dados

O dataset utilizado é o **SKU-110K** (Goldman et al., *Precise Detection in Densely Packed Scenes*, CVPR 2019), disponível publicamente em github.com/eg4000/SKU110K_CVPR19. Consiste em 11.743 imagens reais de prateleiras de supermercado ao redor do mundo, com aproximadamente 1,7 milhão de caixas delimitadoras anotadas (classe única "object"), média de 147 produtos por imagem no split de treino, extremamente denso.

Uma verificação de integridade sobre as anotações do split de treino não encontrou caixa com dimensão inválida nem fora dos limites da imagem, e identificou 42 resoluções distintas de imagem. Condição de

iluminação não foi analisada de forma sistemática.

2.2 Subconjunto A: Detecção

Para a etapa de detecção, foi extraída uma amostra aleatória de 500 imagens (seed fixa, 42), respeitando os splits oficiais do dataset (350 treino, 75 validação, 75 teste), amostradas dentro de cada split para preservar a garantia original de que a mesma loja não aparece em mais de um split. As caixas delimitadoras já existentes no SKU-110K foram reaproveitadas diretamente, sem anotação manual.

2.3 Subconjunto B: Segmentação

A proposta inicial (Fase 1) previa um subconjunto de 80 a 120 imagens para a etapa de segmentação, selecionadas priorizando baixa densidade de objetos. A análise exploratória revelou que imagem esparsa é rara no SKU-110K: no split de treino inteiro (8.219 imagens), apenas 12 imagens têm até 30 objetos, 19 até 40, 28 até 50 e 50 até 60. O dataset foi construído especificamente para representar cenas densamente povoadas, o que limita a margem de escolha.

Diante disso, o critério de seleção foi ajustado para um piso mínimo de 20 objetos por imagem (evitando casos de sinal de treino praticamente nulo, como imagens com apenas 1 ou 6 objetos anotados) e um teto que se expande automaticamente até reunir 28 imagens. A composição final do Subconjunto B:

Estatística	Valor
Total de imagens	28
Densidade média	41,2 objetos/imagem
Densidade mínima	23
Densidade máxima	55




Figura 1: distribuição de objetos por imagem no split de treino do SKU-110K (esquerda: completa; direita: recorte 0-60).

O Subconjunto B é selecionado de forma independente do Subconjunto A (ambos vêm do split de treino, mas por critérios diferentes: volume para A, densidade para B). Isso não compromete a comparação qualitativa entre detecção e segmentação: o SKU-110K fornece caixas delimitadoras para todas as suas imagens, incluindo as do Subconjunto B, independentemente de terem sido usadas no treino do detector.

Sobre o requisito mínimo de 300 imagens anotadas: o enunciado define esse mínimo como item próprio da lista de requisitos, no mesmo nível hierárquico de “Detecção” e “Segmentação”, não como sublinha de cada etapa. Sob essa leitura, o requisito já é atendido integralmente pelo Subconjunto A (500 imagens anotadas, fonte pública citada,

dividido em treino/validação/teste). O Subconjunto B é um recorte interno adicional e não precisa sozinho atingir as 300 imagens. Essa interpretação não é a única gramaticalmente possível e não foi confirmada previamente com o professor.

2.4 Anotação parcial no SKU-110K: um padrão observado

A conferência visual das caixas originais nas 28 imagens do Subconjunto B revelou que o SKU-110K frequentemente anota apenas uma região ou expositor específico da cena, deixando produtos visivelmente presentes no restante da foto sem nenhuma caixa. Em `train_3029.jpg`, por exemplo, uma prateleira inteira de higiene bucal aparece na imagem, mas apenas um único frasco recebeu caixa original. O mesmo padrão aparece em `train_3622.jpg`, `train_2555.jpg`, `train_6216.jpg` e `train_7082.jpg`.

Uma hipótese razoável (inferida do padrão observado, não confirmada pela documentação do dataset): a Trax, mantenedora do SKU-110K, atua em auditoria de prateleira para a indústria de bens de consumo, e é plausível que as fotos tenham sido capturadas por equipes de campo auditando um expositor específico, com a anotação seguindo o mesmo escopo do trabalho de campo.

Diante disso, adotaram-se duas regras para a anotação manual de segmentação:

- **Regra de escopo:** anotar máscara apenas para objetos que já possuíam caixa original do SKU-110K, mesmo quando a imagem contém visivelmente mais produtos fora dessa contagem. Isso mantém a comparação caixa x máscara válida para as 27 imagens que seguem essa regra (a exceção é tratada a seguir).
- **Regra de granularidade:** quando uma única caixa original agrupa múltiplos produtos visualmente distintos (por exemplo, cestas de produtos variados tratadas como uma unidade), cada produto distinguível recebe sua própria máscara, mesmo que isso resulte em mais máscaras do que caixas originais. Itens cuja borda não pode ser distinguida com confiança são deixados sem anotação.

A imagem `train_7082.jpg` é uma exceção documentada: foi anotada de forma exaustiva (incluindo o fundo fora do escopo original) antes da regra de escopo ter sido formalizada, e mantida assim por servir como exemplo ilustrativo mais rico do conjunto. Em consequência, a diferença numérica entre caixas originais e máscaras anotadas (seção 5) reflete em parte critério de anotação, não apenas capacidade da segmentação de revelar informação nova; os dois efeitos são discutidos separadamente na seção 5.

2.5 Categoria sem representação: laticínios/refrigerados

Das 28 imagens do Subconjunto B, nenhuma contém uma seção de laticínios ou produtos refrigerados. A categoria `laticínios_refrigerados`, planejada na proposta inicial, ficou sem nenhuma instância anotada, característica da amostra (sorteada por densidade, sem controle de conteúdo), não do método. O treino seguiu com as três categorias efetivamente representadas: `bebidas`, `snacks_embalados` e `outros`.

3. Metodologia

3.1 Detecção

Modelo: YOLO26n (Ultralytics), pré-treinado em COCO, fine-tuning com classe única (**produto**). Hiperparâmetros: 50 épocas, imgsz=640, batch=16, patience=20, seed 42. Aumento de dados: pipeline padrão do Ultralytics (mosaico, espelhamento horizontal, ajuste de matiz/saturação/valor, entre outros), sem customização adicional.

3.2 Segmentação

Anotação manual das 28 imagens do Subconjunto B no Roboflow, com assistência de segmentação automática por prompt (SAM 3) e por clique (Smart Select), seguida de revisão manual conforme as regras da seção 2.4. Diferente do Subconjunto A, cujo split é reproduzível via seed fixa no código, o split do Subconjunto B (20/4/4) foi definido pelo Roboflow na geração da Version, sem controle de seed pelo pipeline; não há metadado de loja de origem no SKU-110K para confirmar ausência de sobreposição entre esses três subconjuntos, o que permanece como limitação não verificada.

Duas configurações de treino foram testadas, ambas com YOLO26n-seg e o mesmo aumento de dados padrão:

Configuração	Épocas	imgsz	batch	freeze	patience
v1	300 (parou em 129)	640	8	-	50
v2 (final)	300	960	4	10	50

A v2 usa resolução de entrada maior (ajuda a distinguir contorno de objetos pequenos e colados) e congelamento parcial do backbone (preserva conhecimento geral do pré-treino COCO, reduzindo esquecimento ao ajustar o modelo com poucas imagens).

4. Resultados

4.1 Detecção (conjunto de teste, 75 imagens)

Métrica	Validação	Teste
mAP50	0,831	0,820
mAP50-95	0,472	0,471
Precisão	0,864	0,847
Recall	0,782	0,772
IoU médio (detecções corretas)	-	0,793

mAP50 usa como critério de acerto $\text{IoU} \geq 0,5$; mAP50-95 faz a média em limiares de IoU de 0,5 a 0,95. O IoU médio reportado acima foi calculado separadamente, sobre 8.748 pares caixa prevista/caixa anotada que atingiram $\text{IoU} \geq 0,5$ no teste. A proximidade entre

validação e teste é indício de generalização razoável para este conjunto de teste específico, mas não descarta por si só overfitting em padrões que essa amostra não capturaria.

4.2 Segmentação

Métrica	v1 (teste)	v2, final (teste)
mAP50	0,093	0,345
mAP50-95	0,038	0,173
Precisão	0,087	0,323
Recall	0,327	0,599

Por classe, na v2 (teste): **bebidas** obteve recall de 0,909 (contra recall próximo de zero na v1), e **outros** obteve recall de 0,29 (contra 0,17 na v1).

Classe	Validação (4 imagens)	Teste (4 imagens)
bebidas	341 (em 4 imagens)	33 (em 1 imagem)
outros	21 (em 2 imagens)	176 (em 3 imagens)
snacks_embalados	36 (em 2 imagens)	0 (em 0 imagens)

A contagem por classe no split de treino (20 imagens) não está disponível nos logs, que reportam apenas perda agregada por época. A ausência completa de **snacks_embalados** no teste é limitação direta do tamanho do Subconjunto B (seção 6).




Figura 2: curvas de treino da v2 (B: métricas de caixa; M: métricas de máscara). As curvas de validação se estabilizam ao longo do treino, consistente com convergência, embora não seja prova definitiva de que mais dados ou épocas não trariam ganho adicional.

4.3 Validação em Vídeo Real

Além do conjunto de teste (imagens do próprio SKU-110K), os dois modelos foram testados em dois vídeos filmados em um supermercado brasileiro (bebidas e cosméticos/higiene, ~48s e ~56s, câmera em mão, limiar de confiança fixo de 0,25), fora de qualquer distribuição vista em treino.

A detecção manteve desempenho robusto nos dois vídeos, com caixas de alta confiança (0,6 a 0,9) cobrindo a maior parte dos produtos visíveis, mesmo com desfoque de movimento. A primeira tentativa de inferência em vídeo para a segmentação não especificava `imgsz` explicitamente, o que fez o modelo processar a 640px em vez dos 960px usados no treino da v2, uma falha de configuração da inferência, não do

modelo. Corrigido esse parâmetro, a segmentação passou a cobrir a cena de forma densa nos dois vídeos, com máscaras de confiança alta (até 0,97 em cosméticos).

Ainda assim, um padrão de erro ficou evidente: no vídeo de bebidas, a maior parte das garrafas e embalagens foi classificada como **outros** (confiança 0,26 a 0,80), com apenas instâncias esporádicas rotuladas corretamente como **bebidas** (confiança 0,29 a 0,32). Isso é o oposto do que a métrica de teste sugere (**bebidas** com recall de 0,909, o melhor entre as classes), e aponta para confusão de categoria específica desse domínio: as embalagens fotografadas no vídeo (garrafas PET e potes retornáveis brasileiros) diferem visualmente das poucas imagens de **bebidas** usadas no treino, majoritariamente de estilo norte-americano.



Figura 3: frames do vídeo de bebidas. Esquerda, detecção, cobertura densa. Direita, segmentação: a maioria das garrafas é classificada como **outros**, apenas uma instância corretamente como **bebidas** (confiança 0,32).

5. Análise de Erros

Deteção: a matriz de confusão no teste mostra 8.905 acertos, 2.861 falsos positivos e 1.612 falsos negativos. Em cenas densas (uma imagem chegou a 308 objetos anotados), é comum o detector desenhar mais de uma caixa sobre o mesmo produto ou dividir um item colado ao vizinho, o que explica boa parte dos falsos positivos sem indicar erro sistemático de localização. Vale uma ressalva que se aplica a ambos os modelos: como o SKU-110K por vezes não anota todo produto visível na cena (seção 2.4), parte do que é contado como falso positivo (previsão sobre região sem anotação original) pode corresponder a produto de fato presente na cena, apenas não capturado pela anotação, não a erro do modelo. Não há como quantificar essa parcela sem reanotação manual completa; os números de falso positivo reportados devem ser lidos como limite superior do erro efetivo do modelo.




Figura 4: matriz de confusão da detecção no teste.

O exemplo test_1521.jpg (69 objetos anotados) mostra o detector prevendo corretamente a maioria dos produtos, com confiança de até 0,89.



Figura 5: ground truth (esquerda) e predição (direita) em test_1521.jpg.

Segmentação: a matriz de confusão usa um único limiar de confiança fixo; mAP e recall agregam previsões em vários limiares, incluindo confiança mais baixa que a matriz descarta. Isso explica por que a v1 mostra recall de 0,327 na tabela mas diagonal vazia na matriz.




Figura 6: matrizes de confusão da segmentação, v1 (esquerda) e v2 (direita). Na v2, **bebidas** acerta 33 e **outros** acerta 59, mas o modelo também prevê **bebidas** 138 vezes e **outros** 96 vezes sobre fundo sem produto (falsos positivos, com a mesma ressalva de anotação parcial feita para a detecção), o que explica a precisão moderada mesmo com recall alto.

Um exemplo concreto: train_85.jpg... (predominantemente garrafas de refrigerante) não recebeu nenhuma máscara prevista pelo modelo v1, apesar de conter 33 instâncias reais de **bebidas**, batendo com o recall quase nulo dessa versão. A v2 resolveu grande parte desse problema para **bebidas**, mas **outros** permanece mais modesto, reforçando que parte da dificuldade é geométrica (produtos menos padronizados que embalagens de bebida).




Figura 7: ground truth (esquerda) e predição v1 (direita) em `train_85.jpg`...: falso negativo total para **bebidas**.

Comparação caixa x máscara: `train_7082.jpg` (34 caixas contra 237 máscaras) e `train_7716.jpg` (25 caixas contra 69 máscaras) ilustram o que a segmentação acrescenta, mas por motivos diferentes. Em `train_7082.jpg`, a diferença vem majoritariamente da exceção de escopo (anotação exhaustiva do fundo), uma decisão de anotação, não capacidade demonstrada do modelo. Em `train_7716.jpg`, a diferença vem da regra de granularidade (separar itens agrupados numa cesta), um ganho de informação genuíno da segmentação sobre a caixa original.




Figura 8: caixa original (topo) e máscaras anotadas (base) em `train_7082.jpg` (esquerda, exceção de escopo) e `train_7716.jpg` (direita, regra de granularidade).

6. Limitações e Próximos Passos

- O Subconjunto B (28 imagens, 20/4/4) é pequeno, o que aumenta a variância das métricas de segmentação e limita a generalização do modelo, em contraste com o Subconjunto A (500 imagens).
- A categoria **laticínios_refrigerados** não pôde ser avaliada por ausência de dado na amostra, e **snacks_embalados** não aparece no teste pelo mesmo motivo.
- Não há confirmação de que o split 20/4/4 do Subconjunto B esteja livre de sobreposição de loja entre treino/validação/teste, ao contrário do Subconjunto A, garantido por código.
- O desempenho desigual entre **bebidas** e **outros**, mesmo após a melhoria v1 para v2, sugere dificuldade geométrica que não seria resolvida apenas com mais dados.
- A validação em vídeo (seção 4.3) mostrou boa cobertura de segmentação fora do domínio do SKU-110K, mas com confusão sistemática entre **bebidas** e **outros** no vídeo de bebidas, provavelmente ligada à diferença entre embalagens brasileiras e as

usadas no treino.

- Trabalho futuro: ampliar o Subconjunto B com imagens de domínios mais diversos (incluindo mercados brasileiros e `laticinios_refrigerados`), testar arquiteturas maiores da família YOLO26 caso o volume de dado seja ampliado, e investigar a confusão de categoria identificada no vídeo de bebidas.

7. Declaração de Uso de Inteligência Artificial

Ferramenta utilizada: Claude (Anthropic), como apoio ao longo do projeto na geração e correção de código (EDA, pipelines de treino e avaliação, scripts de apoio), na sugestão e implementação de alternativas metodológicas (critério de seleção dos subconjuntos, regras de anotação, ajuste de hiperparâmetros) e na redação e formatação deste relatório, incluindo organização de figuras e legendas.

A execução dos experimentos (anotação manual no Roboflow, treinos no Google Colab, gravação e validação do vídeo de inferência), a análise dos resultados, as decisões metodológicas e a revisão final do conteúdo são de responsabilidade do autor.

8. Referências

- Goldman, E., Herzig, R., Eisenschtat, A., Goldberger, J., Hassner, T. *Precise Detection in Densely Packed Scenes*. CVPR 2019. github.com/eg4000/SKU110K_CVPR19
- Ultralytics YOLO26 (framework de detecção e segmentação). docs.ultralytics.com
- Roboflow (anotação assistida e exportação de dataset de segmentação). roboflow.com
- Anthropic Claude (assistente de IA usado no projeto, seção 7). claude.com