

# Relatório Técnico: Sistema de Visão Computacional para Auditoria de Gôndola (Varejo)

**Aluno:** Leonardo Ramos Coutinho **Disciplina:** Visão Computacional e Reconhecimento de Padrões **Cenário:** Varejo, Detecção e Segmentação de Produtos em Prateleiras

---

## 1. Problema e Cenário

Auditoria de gôndola é uma tarefa recorrente no varejo: verificar presença, quantidade e organização de produtos expostos nas prateleiras, hoje feita majoritariamente de forma manual. Este projeto constrói um sistema de visão computacional que detecta produtos individuais em fotos de prateleira e segmenta cada instância detectada, permitindo estimar ocupação e apoiar decisões de reposição.

O sistema é dividido em duas granularidades complementares:

- Um detector geral de produtos (classe única), treinado sobre uma base ampla de imagens reais de prateleira.
- Um modelo de segmentação por categoria, treinado sobre um subconjunto menor e cuidadosamente selecionado, capaz de distinguir grandes grupos de produtos além de apenas localizá-los.

Essa divisão foi uma escolha deliberada de escopo, dado que o projeto foi desenvolvido por uma única pessoa: anotar segmentação e categoria em todas as instâncias de uma base densamente povoada não é viável no prazo do curso. A estratégia concentra o esforço manual de anotação apenas onde ele é indispensável (segmentação e categoria), e aproveita anotações já existentes para a detecção.

## 2. Dataset e Análise Exploratória

### 2.1 Fonte dos dados

O dataset utilizado é o **SKU-110K** (Goldman et al., *Precise Detection in Densely Packed Scenes*, CVPR 2019), disponível publicamente em [github.com/eg4000/SKU110K\\_CVPR19](https://github.com/eg4000/SKU110K_CVPR19). Consiste em 11.743 imagens reais de prateleiras de supermercado ao redor do mundo, com aproximadamente 1,7 milhão de caixas delimitadoras anotadas (classe única "object"), média de 147 produtos por imagem no split de treino, extremamente denso.

### 2.2 Subconjunto A: Detecção


Para a etapa de detecção, foi extraída uma amostra aleatória de 500 imagens (seed fixa, 42), respeitando os splits oficiais do dataset (350 treino, 75 validação, 75 teste), amostradas dentro de cada split para preservar a garantia original de que a mesma loja não aparece em mais de um split. As caixas delimitadoras já existentes no SKU-110K foram reaproveitadas diretamente, sem anotação manual.

### 2.3 Subconjunto B: Segmentação

A proposta inicial (Fase 1) previa um subconjunto de 80 a 120 imagens para a etapa de segmentação, selecionadas priorizando baixa densidade de objetos. A análise exploratória revelou que imagem esparsa é rara no SKU-110K: no split de treino inteiro (8.219 imagens), apenas 12 imagens têm até 30 objetos, 19 até 40, 28 até 50 e 50 até 60. O dataset foi construído especificamente para representar cenas densamente povoadas, o que limita a margem de escolha.

Diante disso, o critério de seleção foi ajustado para um piso mínimo de 20 objetos por imagem (evitando casos de sinal de treino praticamente nulo, como imagens com apenas 1 ou 6 objetos anotados) e um teto que se expande automaticamente até reunir 28 imagens. A composição final do Subconjunto B é:

| Estatística      | Valor               |
|------------------|---------------------|
| Total de imagens | 28                  |
| Densidade média  | 41,2 objetos/imagem |
| Densidade mínima | 23                  |
| Densidade máxima | 55                  |



*Figura 1: distribuição de objetos por imagem no split de treino do SKU-110K. À esquerda, distribuição completa (cauda longa até ~600 objetos); à direita, recorte 0-60, onde fica visível como poucas imagens ficam abaixo de 60 objetos.*

O Subconjunto B é selecionado de forma independente do Subconjunto A (ambos vêm do split de treino, mas por critérios diferentes: volume para A, densidade para B), sem relação de subconjunto entre eles. Isso não compromete a comparação qualitativa entre detecção e segmentação: o SKU-110K fornece caixas delimitadoras para todas as suas imagens, incluindo as do Subconjunto B, independentemente de terem sido usadas no treino do detector.

**Sobre o requisito mínimo de 300 imagens anotadas:** o enunciado do trabalho define esse mínimo como um item próprio da lista de requisitos, no mesmo nível hierárquico de “Detecção” e “Segmentação”, não como sublinha de cada etapa. Sob essa leitura, o requisito já é atendido integralmente pelo Subconjunto A (500 imagens anotadas, fonte pública citada, dividido em treino/validação/teste). O Subconjunto B é um recorte interno adicional, específico da etapa de segmentação, e não precisa sozinho atingir as 300 imagens.

## 2.4 Anotação parcial no SKU-110K: um padrão observado

A conferência visual das caixas originais nas 28 imagens do Subconjunto B (feita antes de anotar cada uma) revelou que o SKU-110K frequentemente anota apenas uma região ou expositor específico da cena, deixando prateleiras ou produtos visivelmente presentes no restante da foto sem nenhuma caixa. Em `train_3029.jpg`, por exemplo, uma prateleira inteira de higiene bucal aparece na

imagem, mas apenas um único frasco recebeu caixa original. O mesmo padrão aparece em `train_3622.jpg`, `train_2555.jpg`, `train_6216.jpg` e `train_7082.jpg`.

Uma hipótese razoável (inferida do padrão observado, não confirmada pela documentação do dataset): a Trax, mantenedora do SKU-110K, atua em auditoria de prateleira para a indústria de bens de consumo, e é plausível que as fotos originais tenham sido capturadas por equipes de campo auditando um expositor específico, com a anotação seguindo o mesmo escopo do trabalho de campo.

Diante disso, adotaram-se duas regras para a anotação manual de segmentação:

- **Regra de escopo:** anotar máscara apenas para objetos que já possuíam caixa original do SKU-110K, mesmo quando a imagem contém visivelmente mais produtos fora dessa contagem. Isso mantém a comparação caixa x máscara válida para todo o Subconjunto B.
- **Regra de granularidade:** quando uma única caixa original agrupa múltiplos produtos visualmente distintos (por exemplo, cestas de produtos variados tratadas como uma unidade), cada produto distinguível recebe sua própria máscara, mesmo que isso resulte em mais máscaras do que caixas originais. Itens cuja borda não pode ser distinguida com confiança (oclusão, desfoque) são deixados sem anotação, priorizando qualidade da máscara sobre exaustividade da contagem.

A imagem `train_7082.jpg` é uma exceção documentada a essas regras: foi anotada de forma exaustiva (incluindo o fundo fora do escopo original) antes da regra de escopo ter sido formalizada, e mantida assim por servir como exemplo ilustrativo mais rico do conjunto.

## 2.5 Categoria sem representação: laticínios/refrigerados

Das 28 imagens do Subconjunto B, nenhuma contém uma seção de laticínios ou produtos refrigerados. A categoria `laticinios_refrigerados`, planejada na proposta inicial, ficou sem nenhuma instância anotada, uma característica da amostra (sorteada por densidade, sem controle de conteúdo), não do método. O treino de segmentação seguiu com as três categorias efetivamente representadas: `bebidas`, `snacks_embalados` e `outros`.

# 3. Metodologia

## 3.1 Detecção

Modelo: YOLO26n (Ultralytics), pré-treinado em COCO, fine-tuning com classe única (`produto`). Hiperparâmetros: 50 épocas, `imgsz=640`, `batch=16`, `patience=20`, `seed 42`.

## 3.2 Segmentação

Anotação manual das 28 imagens do Subconjunto B realizada no Roboflow, com assistência de segmentação automática por prompt (SAM 3) e por clique (Smart Select), seguida de revisão e correção manual conforme as regras descritas na seção 2.4. Diferente do Subconjunto A, cujo split treino/validação/teste é reproduzível via seed fixa no código, o split do Subconjunto B (20/4/4) foi definido pelo próprio Roboflow na geração da Version, sem controle de seed pelo pipeline.

Duas configurações de treino foram testadas, ambas com YOLO26n-seg:

| Configuração | Épocas             | imgsz | batch | freeze | patience |
|--------------|--------------------|-------|-------|--------|----------|
| v1           | 300 (parou em 129) | 640   | 8     | -      | 50       |
| v2 (final)   | 300                | 960   | 4     | 10     | 50       |

A v2 usa resolução de entrada maior (ajuda a distinguir contorno de objetos pequenos e colados) e congelamento parcial do backbone (preserva conhecimento geral de forma vindo do pré-treino COCO, reduzindo esquecimento ao ajustar o modelo com poucas imagens).

## 4. Resultados

### 4.1 Detecção (conjunto de teste, 75 imagens)

| Métrica  | Validação | Teste |
|----------|-----------|-------|
| mAP50    | 0,831     | 0,820 |
| mAP50-95 | 0,472     | 0,471 |
| Precisão | 0,864     | 0,847 |
| Recall   | 0,782     | 0,772 |

A proximidade entre validação e teste indica boa generalização, sem sinal relevante de overfitting.

### 4.2 Segmentação (conjunto de teste, 4 imagens)

| Métrica  | v1    | v2 (final) |
|----------|-------|------------|
| mAP50    | 0,093 | 0,345      |
| mAP50-95 | 0,038 | 0,173      |
| Precisão | 0,087 | 0,323      |
| Recall   | 0,327 | 0,599      |

Por classe, na v2: **bebidas** obteve recall de 0,909 (contra recall próximo de zero na v1), e **outros** obteve recall de 0,29 (contra 0,17 na v1). A classe **snacks\_embalados** não aparece na avaliação de teste porque nenhuma das 4 imagens de teste contém essa categoria, limitação do tamanho reduzido do Subconjunto B, não do modelo especificamente.




Figura 2: curvas de treino da versão final de segmentação (v2). As colunas B referem-se às métricas de caixa delimitadora e M às de máscara. A ausência de picos e a estabilização das curvas de validação confirmam convergência real, não um corte arbitrário do treino.

## 5. Análise de Erros

**Detecção:** a matriz de confusão no teste mostra 8.905 acertos, 2.861 falsos positivos e 1.612 falsos negativos. Em cenas densas (uma imagem do teste chegou a 308 objetos anotados), é comum o detector desenhar mais de uma caixa sobre o mesmo produto físico ou dividir um item colado ao vizinho em duas detecções, o que explica boa parte dos falsos positivos sem indicar erro sistemático de localização.




Figura 3: matriz de confusão da detecção no conjunto de teste.

O exemplo test\_1521.jpg (69 objetos anotados) mostra o detector prevendo corretamente a maioria dos produtos, com confiança de até 0,89, apesar da leitura visual poluída pela quantidade de rótulos sobrepostos.



Figura 4: ground truth (esquerda) e predição do modelo (direita) em test\_1521.jpg. A poluição visual à direita vem da sobreposição de rótulos de confiança em cena muito densa, não de erro de localização.

**Segmentação:** a matriz de confusão da v1 mostra a diagonal inteira vazia, nenhuma classe teve acerto acima do limiar de confiança padrão.




Figura 5: matriz de confusão da segmentação (v1) no conjunto de teste. A ausência de valores na diagonal principal mostra que nenhuma classe teve acerto confiável nessa versão.




Figura 6: matriz de confusão da segmentação (v2, final) no conjunto de teste. **bebidas** acerta 33 instâncias e **outros** acerta 59, uma melhora clara sobre a v1. Ao mesmo tempo, o modelo prevê **bebidas** 138 vezes e **outros** 96 vezes em regiões de fundo sem produto (falsos positivos), o que explica a precisão moderada da v2 mesmo com recall alto: o modelo passou a ser “generoso” ao apontar produto onde não há, não apenas mais atento onde há.

Um exemplo concreto: a imagem train\_85\_jpg... (predominantemente garrafas de refrigerante) não recebeu nenhuma máscara prevista pelo modelo v1, apesar de conter 33 instâncias reais de **bebidas**, batendo com o recall quase nulo dessa versão.

train\_85.jpg.rf.8433e44f9c9e6636a5bccde0ec415c9a.jpg - ground truth (33 instâncias)



train\_85.jpg.rf.8433e44f9c9e6636a5bccde0ec415c9a.jpg - predição do modelo



Figura 7: ground truth (esquerda) e predição do modelo v1 (direita) em train\_85.jpg. ... Nenhuma máscara foi prevista, falso negativo total para a classe **bebidas** nessa versão.

A v2 resolveu grande parte desse problema para **bebidas**, mas **outros** permanece com desempenho mais modesto, reforçando que parte da dificuldade é geométrica (produtos menos padronizados e mais heterogêneos que embalagens de bebida).

**Comparação caixa x máscara:** train\_7082.jpg (34 caixas originais contra 237 máscaras) evidencia o efeito da anotação parcial do SKU-110K.

train\_7082.jpg - caixa original SKU-110K (34 objetos)



train\_7082.jpg - máscaras anotadas (237 instâncias)



Figura 8: train\_7082.jpg, caixa original do SKU-110K (esquerda, restrita ao pallet em primeiro plano) e máscaras anotadas (direita, incluindo a parede de bebidas ao fundo, fora do escopo original).

train\_7716.jpg (25 caixas originais contra 69 máscaras) evidencia o efeito do agrupamento em cesta sendo desfeito pela segmentação.



Figura 9: *train\_7716.jpg*, caixa original agrupando produtos por cesta (esquerda) e máscaras separando cada item individual dentro de cada cesta (direita).

Ambos os casos mostram a segmentação revelando informação (localização precisa, separação de itens agrupados, categoria semântica) que a detecção por classe única não fornece.

## 6. Limitações e Próximos Passos

- O Subconjunto B (28 imagens, divididas em 20/4/4) é pequeno, o que aumenta a variância das métricas de segmentação reportadas e limita a capacidade de generalização do modelo treinado nessa etapa, em contraste com o Subconjunto A (500 imagens), que tem base estatística mais sólida.
- A categoria **laticínios\_refrigerados** não pôde ser avaliada por ausência de dado na amostra selecionada.
- O desempenho desigual entre **bebidas** e **outros**, mesmo após a melhoria de configuração (v1 para v2), sugere que parte da dificuldade é geométrica e não seria resolvida apenas com mais dados de treino.
- Próximo passo já em andamento: inferência em vídeo real de prateleira (mínimo 30 segundos), para demonstração qualitativa do sistema em condições próximas do uso real.
- Trabalho futuro possível: ampliar o Subconjunto B com imagens adicionais que contemplem **laticínios\_refrigerados**, e testar arquiteturas maiores da família YOLO26 caso o volume de dado seja ampliado.

## 7. Declaração de Uso de Inteligência Artificial

Ferramenta utilizada: Claude (Anthropic), como assistente de codificação e redação ao longo do projeto, incluindo geração e depuração de código (EDA, pipelines de treino e avaliação), apoio metodológico (critério de seleção dos subconjuntos de dados, regras de anotação manual, ajuste de hiperparâmetros) e redação deste relatório técnico.

A execução das etapas (anotação manual no Roboflow, treinos no Google Colab, decisões finais de metodologia, gravação e validação do vídeo de inferência) e a revisão final de todo o conteúdo foram realizadas pelo aluno.

